Laboratório 2: Dados Relacionais com Polars

Benilton S Carvalho

Índice

1 Importação dos Banco de Dados **1**

2 Inspeção das três tabelas: **2**

2.1 Os 5 filmes com as maiores notas (desempate por número de votos) 2

2.2 Gênero mais frequente entre os filmes com nota maior que 8 3

2.3 Os 3 atores/atrizes que mais participaram de filmes com nota maior que 7.5 4

1 Importação dos Banco de Dados

```
import polars as pl

null_values = ["\\N"]

basics = pl.read_csv(
    "title.basics0.tsv.gz",
    separator="\t",
    null_values=null_values,
    infer_schema_length=10000,
)

ratings = pl.read_csv(
    "title.ratings.tsv.gz",
    separator="\t",
    null_values=null_values,
)

principals = pl.read_csv(
    "title.principals0.tsv.gz",
    separator="\t",
    null_values=null_values,
)
```

2 Inspeção das três tabelas:

```
basics.head()
```

tconst str	titleType str	primaryTitle str	originalTitle str	isAdult i64	startYear i64	endYear str	ru i6
”tt0000001”	”short”	”Carmencita”	”Carmencita”	0	1894	null	1
”tt0000002”	”short”	”Le clown et ses chiens”	”Le clown et ses chiens”	0	1892	null	5
”tt0000003”	”short”	”Pauvre Pierrot”	”Pauvre Pierrot”	0	1892	null	5
”tt0000004”	”short”	”Un bon bock”	”Un bon bock”	0	1892	null	12
”tt0000005”	”short”	”Blacksmith Scene”	”Blacksmith Scene”	0	1893	null	1

```
ratings.head()
```

tconst str	averageRating f64	numVotes i64
”tt0000001”	5.7	2092
”tt0000002”	5.6	283
”tt0000003”	6.5	2099
”tt0000004”	5.4	183
”tt0000005”	6.2	2835

```
principals.head()
```

tconst str	ordering i64	nconst str	category str	job str	characters str
”tt0000001”	1	”nm1588970”	”self”	null	”[Self]”
”tt0000001”	2	”nm0005690”	”director”	null	null
”tt0000001”	3	”nm0005690”	”producer”	”producer”	null
”tt0000001”	4	”nm0374658”	”cinematographer”	”director of photography”	null
”tt0000002”	1	”nm0721526”	”director”	null	null

2.1 Os 5 filmes com as maiores notas (desempate por número de votos)

Restringimos a análise a títulos do tipo `movie`, juntamos `basics` com `ratings` por `tconst`, e ordenamos por `averageRating` e, em caso de empate, por `numVotes`, ambos em ordem decrescente.

```
top5 = (
    basics
    .filter(pl.col("titleType") == "movie")
    .join(ratings, on="tconst", how="inner")
    .sort(["averageRating", "numVotes"], descending=[True, True])
    .select(["tconst", "primaryTitle", "startYear", "averageRating", "numVotes"])
    .head(5)
)
top5
```

tconst str	primaryTitle str	startYear i64	averageRating f64	numVotes i64
”tt33075815”	”Kaveri”	2024	10.0	1023
”tt27815015”	”Kurukku”	2024	10.0	451
”tt28450376”	”Jedal Dar Omghe 30 Metri”	2009	10.0	142
”tt27859713”	”Sargashte”	2016	10.0	134
”tt33507675”	”Gorgeous Rascal”	2024	10.0	115

2.2 Gênero mais frequente entre os filmes com nota maior que 8

A coluna `genres` contém múltiplos gêneros separados por vírgula; é preciso separá-los (`str.split`), expandir cada filme em uma linha por gênero (`explode`) e então contar as ocorrências.

```
genre_counts = (
    basics
    .filter(pl.col("titleType") == "movie")
    .join(ratings, on="tconst", how="inner")
    .filter(pl.col("averageRating") > 8)
    .filter(pl.col("genres").is_not_null())
    .with_columns(pl.col("genres").str.split(","))
    .explode("genres")
    .group_by("genres")
    .agg(pl.len().alias("n_filmes"))
    .sort("n_filmes", descending=True)
)

genre_counts.head(10)
```

genres str	n_filmes u32
”Documentary”	10564
”Drama”	8114
”Comedy”	3186

genres str	n_filmes u32
”Biography”	1395
”Romance”	1363
”Action”	1355
”Music”	1248
”Thriller”	1184
”History”	1030
”Crime”	977

```
genero_mais_frequente = genre_counts.row(0)
print(
    f"Gênero mais frequente entre filmes com nota > 8: "
    f"{genero_mais_frequente[0]} ({genero_mais_frequente[1]} filmes)"
)
```

```
Gênero mais frequente entre filmes com nota > 8: Documentary (10564 filmes)
```

2.3 Os 3 atores/atrizes que mais participaram de filmes com nota maior que 7.5

Filtramos `principals` para as categorias `actor` e `actress`, restringimos aos filmes com `averageRating > 7.5` e contamos as participações por `nconst` (identificador da pessoa).

```
top_atores = (
    basics
    .filter(pl.col("titleType") == "movie")
    .join(ratings, on="tconst", how="inner")
    .filter(pl.col("averageRating") > 7.5)
    .join(principals, on="tconst", how="inner")
    .filter(pl.col("category").is_in(["actor", "actress"]))
    .group_by("nconst")
    .agg(pl.len().alias("n_filmes"))
    .sort("n_filmes", descending=True)
    .head(3)
)
top_atores
```

nconst str	n_filmes u32
”nm0004660”	231
”nm0595934”	155
”nm3183374”	124